Trabajo Práctico 1

Antequera Álvaro, Fariña Valentina, Vicencio Joel

Declaración de uso de IA

En el presente trabajo se utilizaron herramientas de inteligencia artificial para la elaboración y revisión del código de Python, la organización de la estructura del documento en LaTeX y la incorporación de tablas, figuras y ecuaciones. También se utilizaron para la búsqueda y revisión de bibliografía académica que permitiera fundamentar la selección de algunas de las variables explicativas incluidas en la Parte I.

1. Parte I. Preparación de los datos

1.1. Elección de variables

A partir de la base de datos de la Encuesta Permanente de Hogares (EPH) correspondientes al primer trimestre de 2026, se selecionaron únicamente a los ocupado (`ESTADO=1`) a quienes luego se los clasificó como formales (`EMPLEO=1`) e informales (`EMPLEO=2`). Entonces, para la construcción de la variable predicha, únicamente se recodificó la variable `EMPLEO` de la siguiente forma:

$$\text{informal}_i = \begin{cases} 1 & \text{si EMPLEO}_i = 2, \\ 0 & \text{si EMPLEO}_i = 1. \end{cases} \tag{1}$$

El conteo inicial encontró que existen 19.560 trabajadores, de los cuales el 55,02 % (10.762) corresponde a formales y el 44,98 % (8.798) a informales.

La selección de las variables (Tabla 1) se realizó a partir de una breve revisión de literatura apoyado por la IA, aunque las variables de residencia hace 5 años (CH16) y régimen de tenencia de la vivienda (II7) fueron directamente selecionadas por la IA. En general estas variables contemplan características demográficas, educativas, laborales, territoriales y del hogar que permitirán predecir la informalidad basada en trabajos previos.

Tabla 1: Set de variables seleccionadas

Variable	Característica	Antecedente
CH03	Parentesco con la persona de referencia del hogar	Casal and Barham (2013)
CH04	Sexo	Formichella and Rojas (2008); Ludmer and Favata (2020)
CH06	Edad	
CH07	Situación conyugal	Casal and Barham (2013)
CH15	Lugar de nacimiento	Ludmer and Favata (2020)
CH16	Lugar de residencia cinco años antes	Propuesta por la IA
NIVEL_ED	Nivel educativo alcanzado	Formichella and Rojas (2008); Alvarez (2025)
INTENSI	Intensidad de la ocupación	Alvarez (2025)
PP04A	Tipo de establecimiento	Bertranou et al. (2013)
PP04C	Tamaño del establecimiento	Cruces et al. (2018); Ludmer and Favata (2020)
P21	Ingreso de la ocupación principal	Alvarez (2025)
REGION	Región estadística	Cristina et al. (2019)
MAS_500	Tamaño del aglomerado	
IX_MEN10	Menores de 10 años en el hogar	Casal and Barham (2013)
II7	Régimen de tenencia de la vivienda	Propuesta por la IA

La consigna indicaba que se debía evitar la elección de las variables que predecían el `EMPLEO`, ya que el modelo utilizaría información que, prácticamente revelaría la clasificación que se busca predecir; es decir, se generaría un poder predictivo artificialmente elevado.

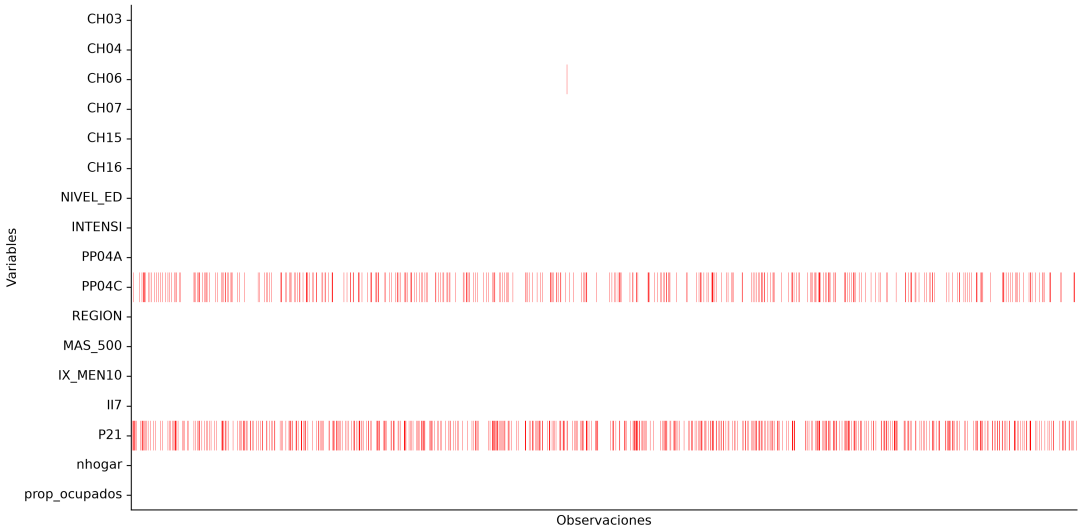
1.2. Construcción de variables

Sumado a lo anterior, se construyeron tres variables adicionales basadas en la propia recomendación de la consigna y estos fueron edad al cuadrado, tamaño del hogar y la proporción de integrantes ocupados. Adicionalmente, se incluyó el logaritmo del ingreso y un indicador de ingreso no declarado para distinguir los valores faltantes de los valores 0 cero.

1.3. Análisis de valores faltantes

Algunas variables presentaban un valor diferente que; por lo general, estaban representados por 9, 99 o −9, en cuyos casos se reeamplazaron por `NaN` segun corresponda. En la Figura 1 se presentan los valores `NaN` por variable y se observa que el ingreso (P21) y en el número de personas que trabajan en el centro laboral (PP04C) concentran la mayor cantidad de `NaN`, que fueron 3719 y 2607 respectivamente.

Figura 1: Heatmap de valores faltantes



Mediante la prueba t de Welch que es utilizada por `scipy.stats.ttest_ind()`, se comparan las medias de los trabajadores informales con las de los formales y algunos resultados se presentan en la Tabla 2.

Tabla 2: Diferencias de medias entre trabajadores formales e informales

Variable	Formales	Informales	Diferencia	t
Edad (años)	43,483	39,393	-4,090	-21,49***
Edad al cuadrado	2.034,084	1.753,447	-280,637	-16,70***
Integrantes del hogar	3,300	3,878	0,579	22,07***
Proporción de ocupados del hogar	0,648	0,627	-0,021	-5,67***
Logaritmo del ingreso	13,748	12,599	-1,150	-38,13***
Ingreso no declarado	0,198	0,180	-0,018	-3,12***
Mujer	0,448	0,461	0,013	1,85*
Menores de 10 años en el hogar	0,352	0,454	0,102	9,86***
Tenencia de vivienda (categoría 2)	0,044	0,071	0,027	7,87***
Tenencia de vivienda (categoría 3)	0,226	0,150	-0,076	-13,71***
Nivel educativo 6	0,364	0,090	-0,274	-49,24***

Nota: $^{***}p < 0{,}01$; $^{**}p < 0{,}05$; $^{*}p < 0{,}10$.

En general, se puede concluir que existen diferencias estadísticamente signifivaticas entre los trabajadores formales e informales, aunque estos resultados no deben interpretarse como relaciones causales. Por ejemplo, trabajadores informales son, en promedio, 4 años menores a los formales o que, en promedio, residen en hogares más numerosos y registran menores ingresos laborales. No obstante, la diferencia entre las proporciones de mujeres no resulta estadísticamente significativa.

1.4. Train y Test split

La muestra final estuvo compuesta por 19.560 trabajadores (observaciones), de los cuales 13.692 corresponden al train group (70 %) y 5.868 al test group (30 %). Esta división permitirá evaluar posteriormente la capacidad de los modelos para predecir la informalidad laboral en observaciones que no fueron utilizadas durante el entrenamiento.

2. Parte II. Regresión logística y análisis discriminante lineal

Inciso 5. Regresión logística

Se estima una regresión logística por máxima verosimilitud sobre la muestra de entrenamiento (13.692 observaciones), tomando como variable dependiente la informalidad y como regresores las 68 variables explicativas de la base limpia (variables numéricas, el indicador de ingreso no declarado y las variables categóricas expresadas como *dummies*, omitiendo una categoría de referencia por variable). La Tabla 3 presenta los coeficientes, sus errores estándar y los *odds ratios* ($e^{\hat{\beta}}$) de las variables más relevantes; la tabla completa, con los 69 parámetros, se encuentra en `B_Table/tabla_logit_completa.csv`.

Tabla 3: Regresión logística: coeficientes, errores estándar y *odds ratios* (variables seleccionadas)

Variable	Coeficiente	Error estándar	*Odds ratio*
Edad	−0,150	0,012	0,861
Edad al cuadrado	0,0014	0,0001	1,0014
Logaritmo del ingreso laboral	−0,316	0,024	0,729
Proporción de ocupados en el hogar	−0,175	0,108	0,839
Secundaria incompleta	−0,440	0,164	0,644
Secundaria completa	−1,157	0,159	0,314
Superior incompleto	−1,308	0,167	0,270
Superior completo	−2,007	0,165	0,134
Sobreocupado (más de 45 hs)	−1,224	0,093	0,294
Sector privado	0,966	0,083	2,627
Otro sector (ni estatal ni privado)	1,697	0,226	5,457
Establecimiento de 101 a 200 ocupados	−2,358	0,183	0,095
Tamaño del establecimiento sin dato	−1,291	0,116	0,275
Región Cuyo	0,807	0,096	2,240
Mujer	0,063	0,052	1,065
Constante	9,154	0,477	9456,138

Interpretación de coeficientes.

Nivel educativo: El coeficiente de tener estudios superiores completos es $-2,007$ (error estándar $0,165$), medido respecto de la categoría de referencia, primario incompleto. Es claramente significativo, ya que el coeficiente es más de doce veces su error estándar. El *odds ratio* es $e^{-2,007} = 0,134$: manteniendo constantes las demás variables, los *odds* de ser informal de una persona con estudios superiores completos son un 86,6 % menores que los de una persona con primario incompleto.

Ingreso laboral: El coeficiente del logaritmo del ingreso es $-0,316$ (error estándar $0,024$), por lo que también es significativo. Dado que la variable está en logaritmos, un aumento del 10 % en el ingreso multiplica los *odds* de informalidad por $1,1^{-0,316} = 0,970$, es decir, los reduce aproximadamente un 3 %, *ceteris paribus*.

Respecto a la diferencia entre el signo y la magnitud de los coeficientes, el signo nos indica la dirección en la que cambia la probabilidad de ser informal, sin embargo la magnitud no se traduce directamente en probabilidad. Esto se debe a que el modelo es lineal en el logaritmo de los *odds*. Un ejemplo de ello es cómo el *odds ratio* de $0,134$ de los estudios superiores completos reduce la probabilidad de informalidad en $38,2$ puntos porcentuales para una persona con probabilidad inicial de 50 % (pasa a $11,8$ %), pero solo en $8,5$ puntos porcentuales para una persona con probabilidad inicial de 10 % (pasa a $1,5$ %). Por lo tanto, el coeficiente nos permite saber el signo y la importancia relativa de cada variable, pero no cuántos puntos porcentuales cambia la probabilidad.

Inciso 6. Probabilidad de informalidad según una variable numérica

En este punto graficamos la probabilidad estimada de ser informal en función de una variable numérica, en este caso el logaritmo del ingreso laboral. Para ello estimamos una regresión logística que utiliza únicamente esa variable como regresor, y evaluamos la probabilidad predicha sobre una grilla de valores del logaritmo del ingreso, entre cero y su valor máximo. En la Figura 2 se presenta la curva estimada junto con los valores observados de la variable dependiente.

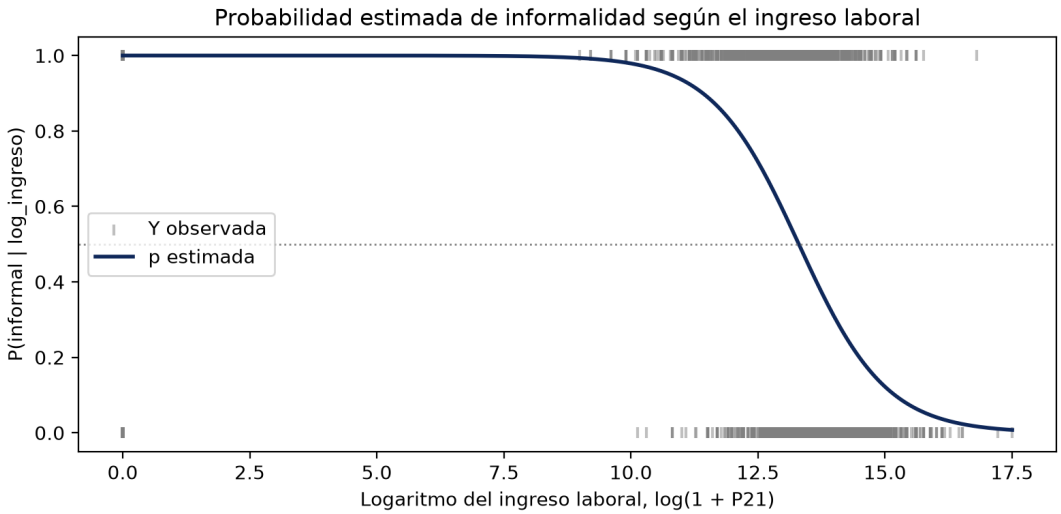


Figura 2: Probabilidad estimada de informalidad según el ingreso laboral

La curva tiene la forma de "S" y es decreciente: a mayor ingreso laboral, menor es la probabilidad estimada de ser informal. Con ingresos bajos la probabilidad de ser informal es prácticamente uno, y a medida que aumenta el ingreso va disminuyendo de forma gradual. Esto es consistente con el signo negativo del coeficiente del logaritmo del ingreso.

Inciso 7. Análisis discriminante lineal

En este punto estimamos un análisis discriminante lineal (LDA) sobre la misma muestra de entrenamiento, con los mismos regresores. A diferencia de la regresión logística, el LDA supone que dentro de cada clase los regresores siguen una distribución normal multivariada. A partir de ese supuesto, y de la probabilidad *a priori* de cada clase, aplica la regla de Bayes para obtener la probabilidad de ser informal dado X.

Con la base de la EPH es difícil sostener este supuesto, debido a que 62 de las 68 variables explicativas son binarias, por lo que casi un 90 % de las variables no pueden tener distribución normal. De las 6 variables numéricas que nos quedan calculamos la curtosis y la asimetría (Tabla 4). Podemos observar que se alejan de cero, por lo que tampoco se asemejan a una distribución normal.

Tabla 4: Asimetría y curtosis en exceso de las variables numéricas, por clase (una normal tiene ambas iguales a cero)

	Asimetría		Curtosis en exceso	
Variable	Formal	Informal	Formal	Informal
Edad	0,17	0,51	−0,55	−0,57
Edad al cuadrado	0,76	1,12	0,43	0,82
Miembros del hogar	1,09	1,44	3,70	4,46
Proporción de ocupados	0,16	0,20	−1,26	−1,15
Log. del ingreso laboral	−8,59	−4,31	91,13	18,47
Menores de 10 años en el hogar	1,86	2,06	3,30	4,98

Aun así, el LDA puede funcionar como clasificador aunque el supuesto no se cumpla exactamente: en la muestra de prueba clasifica igual que la regresión logística el 96, 9 % de las observaciones.

3. Parte III. Vecinos cercanos

Inciso 8. KNN con distintos valores de K

Se procede a estimar vecinos cercanos considerando los siguientes valores del hiperparámetro $K = 10, 50, 100$. Una vez estimados los modelos para los distintos valores correspondientes de K, se calcula el porcentaje de observaciones que el modelo clasifica correctamente *()accuracy)*. Los resultados que se obtienen son los siguientes:

Tabla 5: Exactitud de KNN en entrenamiento

K	Accuracy en train
10	79,36 %
50	76,94 %
100	76,70 %

La elección de K introduce un *trade-off* entre sesgo y varianza, dado que a medida que aumenta el número de vecinos cercanos se consideran observaciones cada vez más alejadas de la observación a clasificar y por lo tanto menos similares, lo que en general reduce la varianza pero aumenta el sesgo. En el extremo cuando $K = 1$, el modelo considera únicamente al vecino más cercano, por lo que presenta un sesgo bajo y una varianza elevada, ya que pequeños cambios en los datos pueden modificar la clasificación. En cambio, cuando $K = n$, se utiliza toda la muestra de entrenamiento para clasificar según la mayoría, lo que reduce la varianza pero aumenta el sesgo dado que considero a todas estas observaciones y no necesariamente a las que están más cercanas.

Inciso 9. Selección de K cross validation

Se selecciona el valor óptimo de K mediante cross validation utilizando una division de cinco partes de la muestra de entrenamiento. De esta manera, en cada iteración se utilizan cuatro partes para estimar el modelo y la restante para evaluar su capacidad de clasificación, calculando el *accuracy*. Luego este procedimiento se repite para distintos valores de K, entre 1 y 1000, y se obtiene el *accuracy* promedio de los cinco bloques para cada valor.

Para evitar utilizar información del bloque de validación, los valores faltantes se imputan y las variables se estandarizan utilizando únicamente las observaciones correspondientes al entrenamiento de cada bloque.

Tabla 6: Exactitud de KNN mediante validación cruzada de cinco folds

K	Accuracy promedio	Desvío entre folds (pp)
1	69,59 %	1,26
3	73,04 %	1,12
5	74,24 %	1,05
10	75,11 %	0,74
15	75,61 %	1,01
20	76,19 %	1,03
25	76,20 %	1,13
30	76,15 %	1,17
40	76,04 %	1,02
50	75,85 %	1,24
75	75,71 %	1,09
100	76,34 %	1,15
150	76,57 %	1,02
200	77,16 %	0,73
300	**77,40 %**	**0,58**
500	77,23 %	0,67
750	76,90 %	0,68
1000	76,77 %	0,83

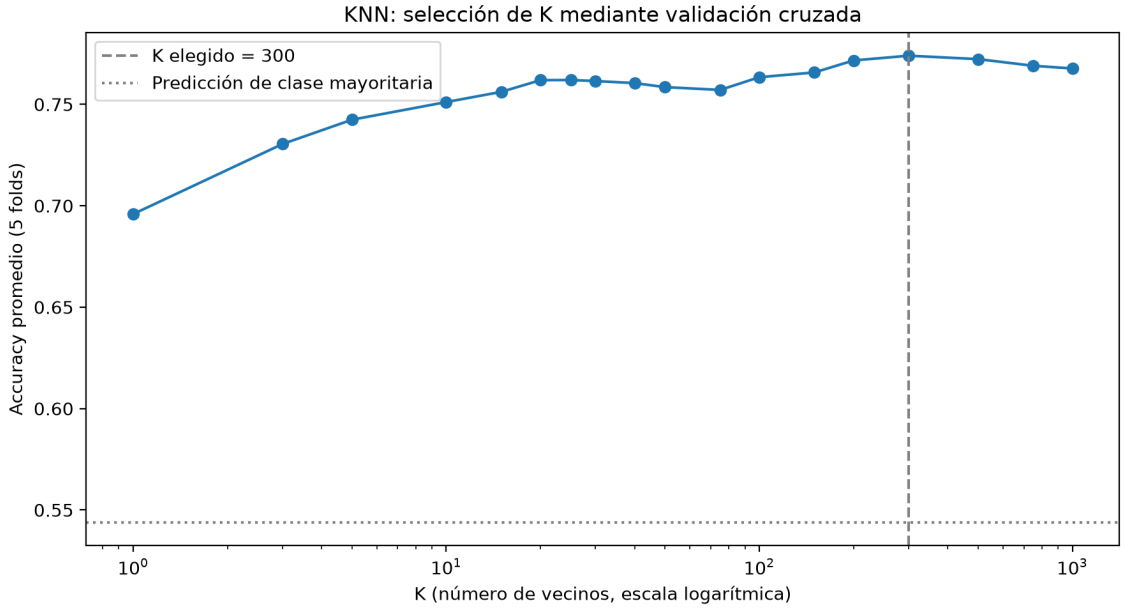


Figura 3: Selección del número de vecinos mediante validación cruzada

Como se observa en la tabla y el gráfico, el *accuracy* promedio alcanza su mayor valor cuando $K = 300$, con un 77,40 % de observaciones correctamente clasificadas. Para valores mayores de K, el *accuracy* comienza a disminuir, por lo que se selecciona $K = 300$ como el valor óptimo dentro de la grilla evaluada (KNN con K-CV).

4. Parte IV. Desempeño de modelos y elección

Inciso 10. Comparación del desempeño en la muestra de testeo

En este punto, luego de estimar los modelos con la base de entrenamiento, comparamos su desempeño en la muestra de testeo. En la Tabla 7 se presentan las matrices de confusión de los tres

modelos, calculadas con el umbral 0, 5, y en la Figura 4 las curvas ROC. Como métricas adicionales calculamos la sensibilidad, que es la proporción de informales correctamente clasificados, y la especificidad, que es la proporción de formales correctamente clasificados (Tabla 8).

Tabla 7: Matrices de confusión en la muestra de testeo (umbral $p > 0,5$)

	Predicho formal (0)	Predicho informal (1)
Logit		
Observado formal (0)	2755	559
Observado informal (1)	531	2023
LDA		
Observado formal (0)	2733	581
Observado informal (1)	526	2028
KNN (K = 300)		
Observado formal (0)	2518	796
Observado informal (1)	445	2109

Tabla 8: Métricas de desempeño en la muestra de testeo (umbral $p > 0,5$)

Modelo	Exactitud	Sensibilidad	Especificidad	VPP	AROC
Logit	0,814	0,792	0,831	0,784	0,892
LDA	0,811	0,794	0,825	0,777	0,888
KNN (K = 300)	0,789	0,826	0,760	0,726	0,872

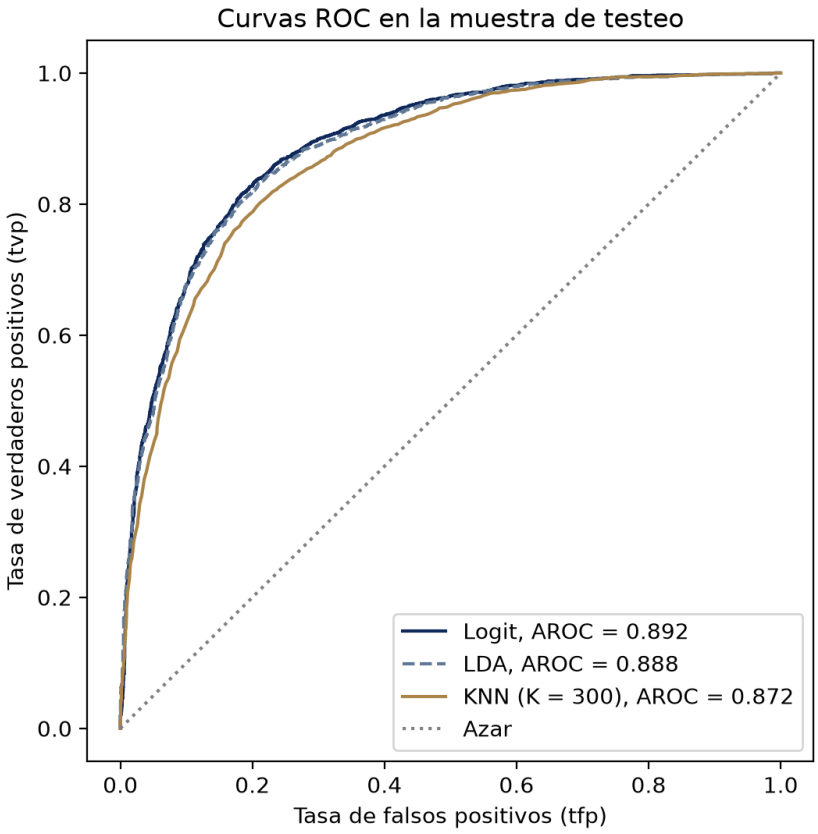


Figura 4: Curvas ROC de los tres modelos en la muestra de testeo

Podemos observar que los tres modelos tienen un desempeño similar: clasifican bien entre el 79 % y el 81 % de las observaciones. Por un lado, la regresión logística y el LDA son casi idénticos: sus matrices de confusión difieren en pocas observaciones y sus curvas ROC casi se superponen. Por otro lado, el KNN es el que menos exactitud tiene (78,9 %) y su curva ROC queda por debajo de las otras dos en casi todo el recorrido. Sin embargo, con el umbral $0,5$ es el modelo con mayor sensibilidad, al costo de perder especificidad.

Con este análisis elegiríamos la regresión logística, ya que es la que tiene mayor exactitud y mayor AROC. Además, a diferencia del LDA, no requiere que los regresores se distribuyan de forma normal, un supuesto que en el inciso 7 vimos que no se cumple en nuestra base. La diferencia con el LDA es muy pequeña, pero la logística resulta una elección más segura.

Inciso 11. Implementación de política

Suponiendo que la secretaría de trabajo esté interesada en identificar a trabajadores informales, sugeriríamos la implementación del modelo de regresión logística para dirigir los recursos de dicho programa.

La elección radica principalmente en que este modelo, además de presentar un nivel de *accuracy* favorable en comparación con los otros modelos, es el que presenta un mayor valor predictivo positivo. Es deseable tener una alta proporción de trabajadores clasificados como informales que sean verdaderamente informales, dado que, una vez identificados, serán alcanzados por el programa y se les destinarán recursos escasos. Por lo tanto, dada la limitación presupuestaria, buscaríamos reducir la cantidad de recursos asignados a trabajadores que ya son formales aunque esto implique dejar afuera a algunos trabajadores informales.

Considerando lo anterior, si bien dejar afuera del programa a un trabajador informal tiene un costo en términos de bienestar, se podría intentar reducir este costo priorizando a aquellos individuos con mayor probabilidad estimada de ser informales. Para ello, se ordenarían los trabajadores de mayor a menor según la probabilidad estimada por el modelo y se seleccionaría a los primeros hasta alcanzar la cantidad de beneficiarios que permita atender el presupuesto disponible. De esta manera, el umbral de clasificación no sería necesariamente 0,5, sino que estaría determinado por la cantidad de trabajadores que puede alcanzar el programa.

Referencias

Alvarez, F. (2025). Predicción del empleo formal en la argentina aplicando algoritmos de aprendizaje automático. *JAIIO, Jornadas Argentinas de Informática*, 11(13):168–179. https://revistas.unlp.edu.ar/JAIIO/article/view/19897.

Bertranou, F., Casanova, L., Jiménez, M., and Jiménez, M. (2013). Informalidad, calidad del empleo y segmentación laboral en argentina. Documento de trabajo 2, Organización Internacional del Trabajo, Buenos Aires. https://www.ilo.org/es/publications/informalidad-calidad-del-empleo-y-segmentacion-laboral-en-argentina.

Casal, M. d. P. and Barham, B. L. (2013). Segmentation and mobility of women in argentine labor markets. *Económica*, 59:89–125. https://revistas.unlp.edu.ar/Economica/article/view/5350.

Cristina, A. D., Figueras, A. J., Iturralde, I., and Blanco, V. J. (2019). Informalidad en los mercados laborales regionales. análisis desde microdatos. Asociación Argentina de Economía Política, Documento de Trabajo 4128. https://ideas.repec.org/p/aep/anales/4128.html.

Cruces, G., Porto, G., and Viollaz, M. (2018). Trade liberalization and informality in argentina. exploring

the adjustment mechanisms. *Latin American Economic Review*, 27(13). https://link.springer.com/article/10.1186/s40503-018-0061-1.

Formichella, M. M. and Rojas, M. (2008). Un aporte a la evidencia empírica del efecto de la educación sobre el empleo formal. *Estudios Económicos*, 25(51). https://revistas.uns.edu.ar/ee/article/view/799.

Ludmer, G. and Favata, F. (2020). Informalidad laboral en la fabricación de ropa en argentina entre 2003–2018. ¿qué aporta la encuesta permanente de hogares? *Estudios Económicos*, 37(74):105–126. https://dialnet.unirioja.es/descarga/articulo/7516425.pdf.