Trabajo Práctico 01

Antequera Álvaro, Fariña Valentina, Vicencio Joel

1. Parte I. Preparación de los datos

1.1. Fuente de información y muestra

El análisis utiliza las bases de datos de la Encuesta Permanente de Hogares (EPH) correspondientes al primer trimestre de 2026. La base individual contiene 43.739 personas y la de hogares comprende 15.447 registros.

Se consideran las personas ocupadas identificadas mediante `ESTADO=1` cuya variable `EMPLEO` adopta los valores 1 o 2. En el ejercicio, el primer código identifica empleo formal y el segundo empleo informal; por lo tanto, la variable dependiente se define como

$$\text{informal}_i = \begin{cases} 1 & \text{si EMPLEO}_i = 2, \\ 0 & \text{si EMPLEO}_i = 1. \end{cases} \tag{1}$$

La muestra final contiene 19.560 trabajadores, de lo cuales el 55,02 % (10.762) corresponde a formales y el 44,98 % (8.798) a informales.

1.2. Selección de variables predictoras

La selección de las variable se realizó en base a la un breve revisión de literatura y contempla seis características demográficas, una educativa, seis laborales y dos territoriales. En la Tabla 1 se presentan las variables.

Tabla 1: Selección de variables originales y respaldo bibliográfico

Variable	Característica	Antecedente
CH03	Parentesco con la persona de referencia del hogar	Casal and Barham (2013), dimensión familiar
CH04	Sexo	Formichella and Rojas (2008); Ludmer and Favata (2020)
CH06	Edad	Formichella and Rojas (2008); Ludmer and Favata (2020)
CH07	Situación conyugal	Casal and Barham (2013)
CH15	Lugar de nacimiento	Ludmer and Favata (2020), origen migratorio
CH16	Lugar de residencia cinco años antes	Predictor exploratorio de movilidad residencial
NIVEL_ED	Nivel educativo alcanzado	Formichella and Rojas (2008); Alvarez (2025)
CAT_OCUP	Categoría ocupacional	Bertranou et al. (2013); Casal and Barham (2013)
INTENSI	Intensidad de la ocupación	Alvarez (2025), dimensión de jornada
PP03C	Una ocupación o varias ocupaciones	Predictor exploratorio de inserción laboral
PP04A	Características del establecimiento	Bertranou et al. (2013), segmentación laboral
PP04C	Tamaño del establecimiento	Cruces et al. (2018); Ludmer and Favata (2020)
P21	Ingreso de la ocupación principal	Alvarez (2025)
REGION	Región estadística	Cristina et al. (2019)
MAS_500	Tamaño del aglomerado	Cristina et al. (2019), dimensión territorial

1.3. Limpieza y construcción de características

Por un lado, el tratamiento de la no respuesta sigue los códigos de cada variable establecidos en el Diseño de Registro. Por lo general, el valor 9 se interpreta como no respuesta únicamente cuando corresponde y se aplicó para `CH15`, `CH16`, `NIVEL_ED`, `CAT_OCUP` e `INTENSI`. El valor 99 de `PP04C` identifica tamaño no declarado y el valor −9 de `P21` identifica ingreso no declarado.

Por otro lado, se construyeron las 3 variables adicionales recomendadas en la consigna. Además, el ingreso declarado se transformó mediante $\log(1 + \text{P21})$ y se construyó un indicador de ingreso no declarado para distinguir los valores faltantes del ingreso cero. Las variables `CODUSU` y `NRO_HOGAR` se utilizan exclusivamente para formar los hogares. Ningún identificador individual o familiar ingresa en la matriz de predictores.

1.4. Análisis de valores faltantes

En la Tabla 1 se presentan los valores faltantes por variable. De ese grupo, los missing values se concentra en el ingreso, pero se preservan las observaciones para no reducir la muestra.

Tabla 2: Valores faltantes en las características seleccionadas

Característica	Observaciones	Porcentaje
Ingreso laboral transformado	3.719	19,013 %
Lugar de nacimiento	2	0,010 %
Residencia anterior	1	0,005 %

Los missing values numéricos se imputan con la mediana calculada exclusivamente en entrenamiento. Posteriormente, esa misma mediana se aplica al conjunto de prueba. Este procedimiento evita utilizar información de prueba durante la preparación del modelo.

1.5. Comparación descriptiva entre formales e informales

Mediante la prueba t de Welch, se comparan las medias de los trabajadores informales con la de los formales y algunos resultados se presentan en la Tabla 3. Los trabajadores informales tienen una

Tabla 3: Diferencias de medias por condición laboral

Característica	Formal	Informal	Diferencia	Valor p
Edad	43,483	39,400	−4, 083	< 0,001
Edad al cuadrado	2.034,084	1.754,370	−279, 714	< 0,001
Integrantes del hogar	3,300	3,878	0,579	< 0,001
Proporción de ocupados	0,648	0,627	−0, 021	< 0,001
Logaritmo del ingreso	13,787	12,380	−1, 407	< 0,001
Ingreso no declarado	0,198	0,180	−0, 018	0,002
Mujer	0,448	0,461	0,013	0,065
Asalariado	0,808	0,596	−0, 212	< 0,001
Nivel educativo 6	0,364	0,090	−0, 274	< 0,001

edad media inferior en 4,08 años. También residen en hogares más numerosos y registran menores ingresos laborales declarados. Por el contrario, la diferencia entre las proporciones de mujeres no resulta estadísticamente significativa al 5 % en este contraste sin ponderación. Estas asociaciones son compatibles con el interés de la literatura en las características individuales y de los puestos de trabajo (Formichella and Rojas, 2008; Ludmer and Favata, 2020). Sin embargo, no establecen relaciones causales.

1.6. Codificación y división de la muestra

Las características categóricas se representan mediante variables indicadoras. Se omite una categoría de referencia por característica y se incorpora un intercepto. Luego se divide aleatoriamente la muestra en un 70 % para entrenamiento y un 30 % para prueba, con `random_state=444`. Así se obtienen 13.692 observaciones de entrenamiento y 5.868 de prueba. La proporción de informalidad alcanza el 45,60 % en entrenamiento y el 43,52 % en prueba. La partición no fue estratificada.

La expansión categórica genera 65 columnas antes de añadir el intercepto. Se detecta una dependencia lineal exacta y se retira una columna redundante correspondiente a una categoría sin dato de residencia anterior. La matriz final conserva 65 columnas, incluido el intercepto, y presenta rango completo en entrenamiento. La decisión responde a la estructura algebraica observada en la muestra y no a pruebas de significancia individual.

Finalmente, la base preparada conserva las 19.560 observaciones con la identificación de su pertenencia a entrenamiento o prueba. Esta información permite utilizar la misma partición para comparar posteriormente regresión logística, análisis discriminante lineal y vecinos más cercanos.

Referencias

Alvarez, F. (2025). Predicción del empleo formal en la argentina aplicando algoritmos de aprendizaje automático. *JAIIO, Jornadas Argentinas de Informática*, 11(13):168–179.

Bertranou, F., Casanova, L., Jiménez, M., and Jiménez, M. (2013). Informalidad, calidad del empleo y segmentación laboral en argentina. Documento de trabajo 2, Organización Internacional del Trabajo, Buenos Aires.

Casal, M. d. P. and Barham, B. L. (2013). Segmentation and mobility of women in argentine labor markets. *Económica*, 59:89–125.

Cristina, D., Figueras, A. J., Iturralde, I., and Blanco, V. (2019). Informalidad laboral en argentina. el rol de aspectos jurisdiccionales sobre la persistencia de la problemática. Trabajo presentado en jornadas de investigación económica.

Cruces, G., Porto, G., and Viollaz, M. (2018). Trade liberalization and informality in argentina. exploring the adjustment mechanisms. *Latin American Economic Review*, 27(13).

Formichella, M. M. and Rojas, M. (2008). Un aporte a la evidencia empírica del efecto de la educación sobre el empleo formal. *Estudios Económicos*, 25(51).

INDEC (2026a). Encuesta permanente de hogares. bases de microdatos del primer trimestre de 2026. Base individual y base de hogares. INDEC, Argentina.

INDEC (2026b). Encuesta permanente de hogares. diseño de registro del primer trimestre de 2026. Documentación de los microdatos de personas y hogares. INDEC, Argentina.

Ludmer, G. and Favata, F. (2020). Informalidad laboral en la fabricación de ropa en argentina entre 2003–2018. ¿qué aporta la encuesta permanente de hogares? *Estudios Económicos*, 37(74):105–126.