Trabajo Práctico 01

Antequera Álvaro, Fariña Valentina, Vicencio Joel

1. Parte I. Preparación de los datos

1.1. Elección de variables

A partir de la base de datos de la Encuesta Permanente de Hogares (EPH) correspondientes al primer trimestre de 2026, se selecionaron únicamente a los ocupado (`ESTADO=1`) a quienes luego se los clasificó como formales (`EMPLEO=1`) e informales (`EMPLEO=2`). Entonces, para la construcción de la variable predicha, únicamente se recodificó la variable `EMPLEO` de la siguiente forma:

$$\text{informal}_i = \begin{cases} 1 & \text{si EMPLEO}_i = 2, \\ 0 & \text{si EMPLEO}_i = 1. \end{cases} \tag{1}$$

El conteo inicial encontró que existen 19.560 trabajadores, de los cuales el 55,02 % (10.762) corresponde a formales y el 44,98 % (8.798) a informales.

La selección de las variables (Tabla 1) se realizó a partir de una breve revisión de literatura apoyado por la IA, aunque las variables de residencia hace 5 años (CH16) y régimen de tenencia de la vivienda (II7) fueron directamente selecionadas por la IA. En general estas variables contemplan características demográficas, educativas, laborales, territoriales y del hogar que permitirán predecir la informalidad basada en trabajos previos.

Tabla 1: Set de variables seleccionadas

Variable	Característica	Antecedente
`CH03`	Parentesco con la persona de referencia del hogar	Casal and Barham (2013)
`CH04`	Sexo	Formichella and Rojas (2008); Ludmer and Favata (2020)
`CH06`	Edad	
`CH07`	Situación conyugal	Casal and Barham (2013)
`CH15`	Lugar de nacimiento	Ludmer and Favata (2020)
`CH16`	Lugar de residencia cinco años antes	Propuesta por la IA
`NIVEL_ED`	Nivel educativo alcanzado	Formichella and Rojas (2008); Alvarez (2025)
`INTENSI`	Intensidad de la ocupación	Alvarez (2025)
`PP04A`	Tipo de establecimiento	Bertranou et al. (2013)
`PP04C`	Tamaño del establecimiento	Cruces et al. (2018); Ludmer and Favata (2020)
`P21`	Ingreso de la ocupación principal	Alvarez (2025)
`REGION`	Región estadística	Cristina et al. (2019)
`MAS_500`	Tamaño del aglomerado	
`IX_MEN10`	Menores de 10 años en el hogar	Casal and Barham (2013)
`II7`	Régimen de tenencia de la vivienda	Propuesta por la IA

La consigna indicaba que se debía evitar la elección de las variables que predecían el `EMPLEO`, ya que el modelo utilizaría información que, prácticamente revelaría la clasificación que se busca predecir; es decir, se generaría un poder predictivo artificialmente elevado.

1.2. Construcción de variables

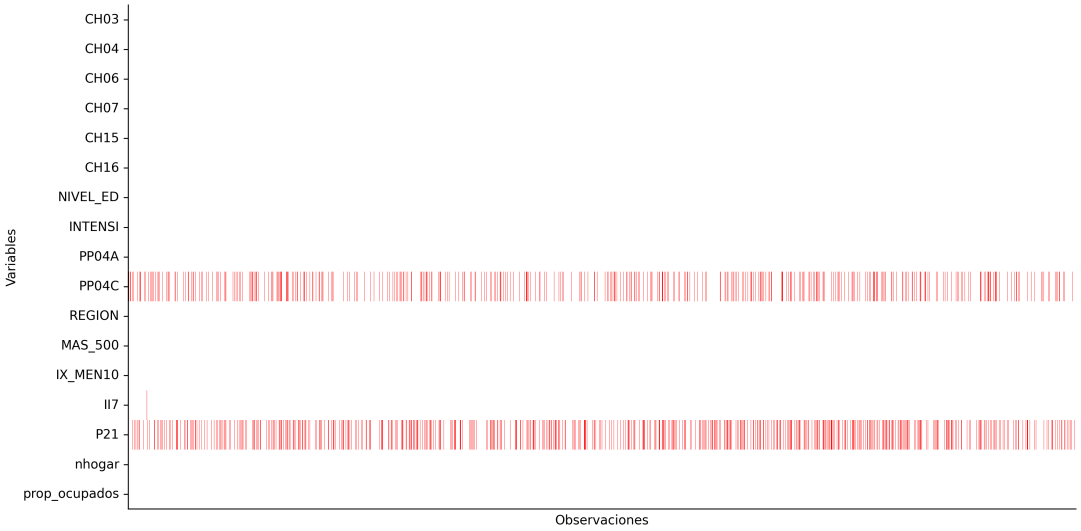
Sumado a lo anterior, se construyeron tres variables adicionales basadas en la propia recomendación de la consigna y estos fueron edad al cuadrado, tamaño del hogar y la proporción de integrantes

ocupados. Adicionalmente, se incluyó el logaritmo del ingreso y un indicador de ingreso no declarado para distinguir los valores faltantes de los valores 0 cero.

1.3. Análisis de valores faltantes

Algunas variables presentaban un valor diferente que; por lo general, estaban representados por 9, 99 o −9, en cuyos casos se reeamplazaron por `NaN` segun corresponda. En la Figura 1 se presentan los valores `NaN` por variable y se observa que el ingreso (P21) y en el número de personas que trabajan en el centro laboral (PP04C) concentran la mayor cantidad de `NaN`, que fueron 3719 y 2607 respectivamente.

Figura 1: Heatmap de valores faltantes



Mediante la prueba t de Welch que es utilizada por `scipy.stats.ttest_ind()`, se comparan las medias de los trabajadores informales con las de los formales y algunos resultados se presentan en la Tabla 2.

Tabla 2: Diferencias de medias entre trabajadores formales e informales

Variable	Formales	Informales	Diferencia	t
Edad (años)	43,483	39,393	-4,090	-21,49***
Edad al cuadrado	2.034,084	1.753,447	-280,637	-16,70***
Integrantes del hogar	3,300	3,878	0,579	22,07***
Proporción de ocupados del hogar	0,648	0,627	-0,021	-5,67***
Logaritmo del ingreso	13,748	12,599	-1,150	-38,13***
Ingreso no declarado	0,198	0,180	-0,018	-3,12***
Mujer	0,448	0,461	0,013	1,85*
Menores de 10 años en el hogar	0,352	0,454	0,102	9,86***
Tenencia de vivienda (categoría 2)	0,044	0,071	0,027	7,87***
Tenencia de vivienda (categoría 3)	0,226	0,150	-0,076	-13,71***
Nivel educativo 6	0,364	0,090	-0,274	-49,24***

Nota: $^{***}p < 0{,}01$; $^{**}p < 0{,}05$; $^{*}p < 0{,}10$.

En general, se puede concluir que existen diferencias estadísticamente signifivaticas entre los trabajadores formales e informales, aunque estos resultados no deben interpretarse como relaciones causales. Por ejemplo, trabajadores informales son, en promedio, 4 años menores a los formales o

que, en promedio, residen en hogares más numerosos y registran menores ingresos laborales. No obstante, la diferencia entre las proporciones de mujeres no resulta estadísticamente significativa.

1.4. Train y Test split

La muestra final estuvo compuesta por 19.560 trabajadores (observaciones), de los cuales 13.692 corresponden al train group (70 %) y 5.868 al test group (30 %). Esta división permitirá evaluar posteriormente la capacidad de los modelos para predecir la informalidad laboral en observaciones que no fueron utilizadas durante el entrenamiento.

Referencias

Alvarez, F. (2025). Predicción del empleo formal en la argentina aplicando algoritmos de aprendizaje automático. *JAIIO, Jornadas Argentinas de Informática*, 11(13):168–179. https://revistas.unlp.edu.ar/JAIIO/article/view/19897.

Bertranou, F., Casanova, L., Jiménez, M., and Jiménez, M. (2013). Informalidad, calidad del empleo y segmentación laboral en argentina. Documento de trabajo 2, Organización Internacional del Trabajo, Buenos Aires. https://www.ilo.org/es/publications/informalidad-calidad-del-empleo-y-segmentacion-laboral-en-argentina.

Casal, M. d. P. and Barham, B. L. (2013). Segmentation and mobility of women in argentine labor markets. *Económica*, 59:89–125. https://revistas.unlp.edu.ar/Economica/article/view/5350.

Cristina, A. D., Figueras, A. J., Iturralde, I., and Blanco, V. J. (2019). Informalidad en los mercados laborales regionales. análisis desde microdatos. Asociación Argentina de Economía Política, Documento de Trabajo 4128. https://ideas.repec.org/p/aep/anales/4128.html.

Cruces, G., Porto, G., and Viollaz, M. (2018). Trade liberalization and informality in argentina. exploring the adjustment mechanisms. *Latin American Economic Review*, 27(13). https://link.springer.com/article/10.1186/s40503-018-0061-1.

Formichella, M. M. and Rojas, M. (2008). Un aporte a la evidencia empírica del efecto de la educación sobre el empleo formal. *Estudios Económicos*, 25(51). https://revistas.uns.edu.ar/ee/article/view/799.

Ludmer, G. and Favata, F. (2020). Informalidad laboral en la fabricación de ropa en argentina entre 2003–2018. ¿qué aporta la encuesta permanente de hogares? *Estudios Económicos*, 37(74):105–126. https://dialnet.unirioja.es/descarga/articulo/7516425.pdf.