Trabajo Práctico 01

Antequera Álvaro, Fariña Valentina, Vicencio Joel

1. Parte I. Preparación de los datos

1.1. Fuente de información y muestra

El análisis utiliza las bases de datos de la Encuesta Permanente de Hogares (EPH) correspondientes al primer trimestre de 2026. La base individual contiene 43.739 personas y la de hogares comprende 15.447 registros.

Se consideran las personas ocupadas identificadas mediante `ESTADO=1` cuya variable `EMPLEO` adopta los valores 1 o 2. En el ejercicio, el primer código identifica empleo formal y el segundo empleo informal; por lo tanto, la variable dependiente se define como

$$\text{informal}_i = \begin{cases} 1 & \text{si EMPLEO}_i = 2, \\ 0 & \text{si EMPLEO}_i = 1. \end{cases} \tag{1}$$

La muestra final contiene 19.560 trabajadores, de los cuales el 55,02 % (10.762) corresponde a formales y el 44,98 % (8.798) a informales.

1.2. Selección de variables predictoras

La selección de las variables se realizó a partir de una breve revisión de literatura y contempla seis características demográficas, una educativa, cuatro laborales, dos territoriales y dos del hogar. En la Tabla 1 se presentan las variables.

Tabla 1: Selección de variables originales y respaldo bibliográfico

Variable	Característica	Antecedente
CH03	Parentesco con la persona de referencia del hogar	Casal and Barham (2013), dimensión familiar
CH04	Sexo	Formichella and Rojas (2008); Ludmer and Favata (2020)
CH06	Edad	Formichella and Rojas (2008); Ludmer and Favata (2020)
CH07	Situación conyugal	Casal and Barham (2013)
CH15	Lugar de nacimiento	Ludmer and Favata (2020), origen migratorio
CH16	Lugar de residencia cinco años antes	Predictor exploratorio de movilidad residencial
NIVEL_ED	Nivel educativo alcanzado	Formichella and Rojas (2008); Alvarez (2025)
INTENSI	Intensidad de la ocupación	Alvarez (2025), dimensión de jornada
PP04A	Características del establecimiento	Bertranou et al. (2013), segmentación laboral
PP04C	Tamaño del establecimiento	Cruces et al. (2018); Ludmer and Favata (2020)
P21	Ingreso de la ocupación principal	Alvarez (2025)
REGION	Región estadística	Cristina et al. (2019)
MAS_500	Tamaño del aglomerado	Cristina et al. (2019), dimensión territorial
IX_MEN10	Menores de 10 años en el hogar	Casal and Barham (2013), dimensión familiar
II7	Régimen de tenencia de la vivienda	Predictor exploratorio de situación habitacional

1.3. Limpieza y construcción de características

Por un lado, el tratamiento de la no respuesta sigue los códigos de cada variable establecidos en el Diseño de Registro. Por lo general, el valor 9 se interpreta como no respuesta únicamente cuando corresponde y se aplicó para `CH15`, `CH16`, `NIVEL_ED` e `INTENSI`. El valor 99 de `CH06` se considera edad no declarada, mientras que el 99 de `PP04C` identifica tamaño no declarado y el valor −9 de `P21` identifica ingreso no declarado. Asimismo, el código 0 de `II7` se trata como no aplicable y se imputa con la moda de entrenamiento antes de codificar la tenencia de vivienda.

Por otro lado, se construyeron las tres variables adicionales recomendadas en la consigna, correspondientes a la edad al cuadrado, el tamaño del hogar y la proporción de integrantes ocupados. Además, el ingreso declarado se transformó mediante $\log(1 + \text{P21})$ y se construyó un indicador de ingreso no declarado para distinguir los valores faltantes del ingreso cero. Las variables `CODUSU` y `NRO_HOGAR` se utilizan exclusivamente para formar los hogares. Ningún identificador individual o familiar ingresa en la matriz de predictores.

1.4. Análisis de valores faltantes

En la Tabla 2 se presentan los valores faltantes por variable. De ese grupo, los valores faltantes se concentran en el ingreso y el tamaño del establecimiento, pero se preservan las observaciones para no reducir la muestra.

Tabla 2: Valores faltantes en las características seleccionadas

Característica	Observaciones	Porcentaje
Ingreso laboral transformado	3.719	19,013 %
Tamaño del establecimiento	2.607	13,328 %
Tenencia de vivienda	5	0,026 %
Lugar de nacimiento	2	0,010 %
Residencia anterior	1	0,005 %
Edad	1	0,005 %

La Figura 1 presenta el patrón de valores faltantes antes de la imputación.



Figura 1: Valores faltantes en la matriz de predictores antes de imputar

Los valores faltantes de edad e ingreso se imputan con la mediana calculada exclusivamente en entrenamiento. Para las variables categóricas, `CH15` y `PP04C` conservan una categoría `sin_dato`,

mientras que CH16 e II7 se imputan con la moda de entrenamiento. Posteriormente, los mismos criterios se aplican al conjunto de prueba. Este procedimiento evita utilizar información de prueba durante la preparación del modelo.

1.5. Comparación descriptiva entre formales e informales

Mediante la prueba t de Welch, se comparan las medias de los trabajadores informales con las de los formales y algunos resultados se presentan en la Tabla 3. Las medias corresponden a los predictores preparados para el modelado, después de imputar los valores faltantes.

Tabla 3: Diferencias de medias por condición laboral

Característica	Formal	Informal	Diferencia	Valor p
Edad	43,483	39,393	−4, 090	< 0,001
Edad al cuadrado	2.034,084	1.753,447	−280, 637	< 0,001
Integrantes del hogar	3,300	3,878	0,579	< 0,001
Proporción de ocupados	0,648	0,627	−0, 021	< 0,001
Logaritmo del ingreso	13,748	12,599	−1, 150	< 0,001
Ingreso no declarado	0,198	0,180	−0, 018	0,002
Mujer	0,448	0,461	0,013	0,065
Menores de 10 años en el hogar	0,352	0,454	0,102	< 0,001
Tenencia de vivienda (categoría 2)	0,044	0,071	0,027	< 0,001
Tenencia de vivienda (categoría 3)	0,226	0,150	−0, 076	< 0,001
Nivel educativo 6	0,364	0,090	−0, 274	< 0,001

Los trabajadores informales tienen una edad media inferior en 4,09 años. También residen en hogares más numerosos y registran menores ingresos laborales después de la imputación. Por el contrario, la diferencia entre las proporciones de mujeres no resulta estadísticamente significativa al 5 % en este contraste sin ponderación. Estas asociaciones son compatibles con el interés de la literatura en las características individuales y de los puestos de trabajo (Formichella and Rojas, 2008; Ludmer and Favata, 2020). Sin embargo, no establecen relaciones causales.

1.6. Codificación y división de la muestra

La muestra se divide aleatoriamente en un 70 % para entrenamiento y un 30 % para prueba, con `random_state=444`. Las características categóricas se representan luego mediante variables indicadoras, ajustando el codificador en entrenamiento y aplicándolo a prueba. Se omite una categoría de referencia por característica y se incorpora un intercepto. Así se obtienen 13.692 observaciones de entrenamiento y 5.868 de prueba. La proporción de informalidad alcanza el 45,60 % en entrenamiento y el 43,52 % en prueba. La partición no fue estratificada.

La expansión categórica genera 68 columnas indicadoras y numéricas antes de añadir el intercepto. La matriz final conserva 69 columnas, incluido el intercepto, y presenta rango completo en entrenamiento. La única observación con CH16 faltante pertenece al conjunto de prueba y se imputa con la moda de entrenamiento.

Finalmente, la base preparada conserva las 19.560 observaciones con la identificación de su pertenencia a entrenamiento o prueba. Esta información permite utilizar la misma partición para comparar posteriormente regresión logística, análisis discriminante lineal y vecinos más cercanos.

2. Parte III. Vecinos cercanos

Inciso 8. KNN con distintos valores de K

Se procede a estimar vecinos cercanos considerando los siguientes valores del hiperparámetro $K = 10, 50, 100$. Una vez estimados los modelos para los distintos valores correspondientes de K, se calcula el porcentaje de observaciones que el modelo clasifica correctamente *()accuracy)*. Los resultados que se obtienen son los siguientes:

Tabla 4: Exactitud de KNN en entrenamiento

K	Accuracy en train
10	79,36 %
50	76,94 %
100	76,70 %

La elección de K introduce un *trade-off* entre sesgo y varianza, dado que a medida que aumenta el número de vecinos cercanos se consideran observaciones cada vez más alejadas de la observación a clasificar y por lo tanto menos similares, lo que en general reduce la varianza pero aumenta el sesgo. En el extremo cuando $K = 1$, el modelo considera únicamente al vecino más cercano, por lo que presenta un sesgo bajo y una varianza elevada, ya que pequeños cambios en los datos pueden modificar la clasificación. En cambio, cuando $K = n$, se utiliza toda la muestra de entrenamiento para clasificar según la mayoría, lo que reduce la varianza pero aumenta el sesgo dado que considero a todas estas observaciones y no necesariamente a las que están más cercanas.

Inciso 9. Selección de K cross validation

Se selecciona el valor óptimo de K mediante cross validation utilizando una division de cinco partes de la muestra de entrenamiento. De esta manera, en cada iteración se utilizan cuatro partes para estimar el modelo y la restante para evaluar su capacidad de clasificación, calculando el *accuracy*. Luego este procedimiento se repite para distintos valores de K, entre 1 y 1000, y se obtiene el *accuracy* promedio de los cinco bloques para cada valor.

Para evitar utilizar información del bloque de validación, los valores faltantes se imputan y las variables se estandarizan utilizando únicamente las observaciones correspondientes al entrenamiento de cada bloque.

Tabla 5: Exactitud de KNN mediante validación cruzada de cinco folds

K	Accuracy promedio	Desvío entre folds (pp)
1	69,59 %	1,26
3	73,04 %	1,12
5	74,24 %	1,05
10	75,11 %	0,74
15	75,61 %	1,01
20	76,19 %	1,03
25	76,20 %	1,13
30	76,15 %	1,17
40	76,04 %	1,02
50	75,85 %	1,24
75	75,71 %	1,09
100	76,34 %	1,15
150	76,57 %	1,02
200	77,16 %	0,73
300	**77,40 %**	**0,58**
500	77,23 %	0,67
750	76,90 %	0,68
1000	76,77 %	0,83

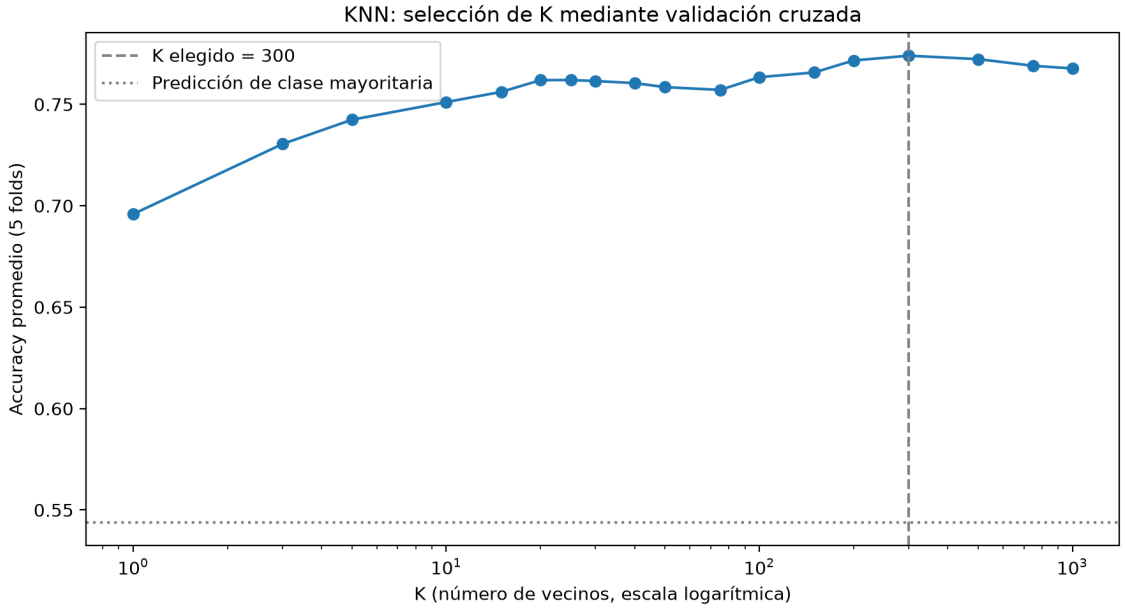


Figura 2: Selección del número de vecinos mediante validación cruzada

Como se observa en la tabla y el gráfico, el *accuracy* promedio alcanza su mayor valor cuando $K = 300$, con un 77,40 % de observaciones correctamente clasificadas. Para valores mayores de K, el *accuracy* comienza a disminuir, por lo que se selecciona $K = 300$ como el valor óptimo dentro de la grilla evaluada (KNN con K-CV).

Referencias

Alvarez, F. (2025). Predicción del empleo formal en la argentina aplicando algoritmos de aprendizaje automático. *JAIIO, Jornadas Argentinas de Informática*, 11(13):168–179.

Bertranou, F., Casanova, L., Jiménez, M., and Jiménez, M. (2013). Informalidad, calidad del empleo

y segmentación laboral en argentina. Documento de trabajo 2, Organización Internacional del Trabajo, Buenos Aires.

Casal, M. d. P. and Barham, B. L. (2013). Segmentation and mobility of women in argentine labor markets. *Económica*, 59:89–125.

Cristina, D., Figueras, A. J., Iturralde, I., and Blanco, V. (2019). Informalidad laboral en argentina. el rol de aspectos jurisdiccionales sobre la persistencia de la problemática. Trabajo presentado en jornadas de investigación económica.

Cruces, G., Porto, G., and Viollaz, M. (2018). Trade liberalization and informality in argentina. exploring the adjustment mechanisms. *Latin American Economic Review*, 27(13).

Formichella, M. M. and Rojas, M. (2008). Un aporte a la evidencia empírica del efecto de la educación sobre el empleo formal. *Estudios Económicos*, 25(51).

INDEC (2026a). Encuesta permanente de hogares. bases de microdatos del primer trimestre de 2026. Base individual y base de hogares. INDEC, Argentina.

INDEC (2026b). Encuesta permanente de hogares. diseño de registro del primer trimestre de 2026. Documentación de los microdatos de personas y hogares. INDEC, Argentina.

Ludmer, G. and Favata, F. (2020). Informalidad laboral en la fabricación de ropa en argentina entre 2003–2018. ¿qué aporta la encuesta permanente de hogares? *Estudios Económicos*, 37(74):105–126.